

# R et la prévision des séries temporelles

## Chapitre 2 - Quelques outils pour le prévisionniste

Michel CARBON

Université Laval de Québec

13 mai 2019




Michel CARBON

R et la prévision des séries temporelles Chapitre 2 - Quelq

## Quelques méthodes simples de prévision

Série mensuelle du nombre de porcs abattus dans une province




Michel CARBON

R et la prévision des séries temporelles Chapitre 2 - Quelq

Comment feriez-vous des prévisions à partir de cette série ?

## Quelques méthodes simples de prévision - suite

Production trimestrielle de bière



Michel CARBON

R et la prévision des séries temporelles Chapitre 2 - Quelq

## Quelques méthodes simples de prévision - suite

### 1 Méthode de la moyenne :

- Toutes les prévisions des valeurs futures sont égales à la moyenne des données historiques.

$$\hat{x}_{T+h|T} = \frac{1}{T}(x_1 + \dots + x_T)$$

### 2 Méthode naïve :

- Toutes les prévisions sont égales à la dernière observation.

$$\hat{x}_{T+h|T} = x_T$$



Michel CARBON

R et la prévision des séries temporelles Chapitre 2 - Quelq

Comment feriez-vous des prévisions à partir de cette série ?

## Quelques méthodes simples de prévision - suite

## ③ Méthode naïve saisonnière :

- Toutes les prévisions sont égales à la dernière valeur de la précédente saison.
- $\hat{x}_{T+h|T} = x_{T+h-m(k+1)}$  où  $m$  = longueur de la saison et  $h$  est la partie entière de  $(h-1)/m$ .

## ④ Méthode de la dérive :

- Les prévisions sont calculées via la formule :

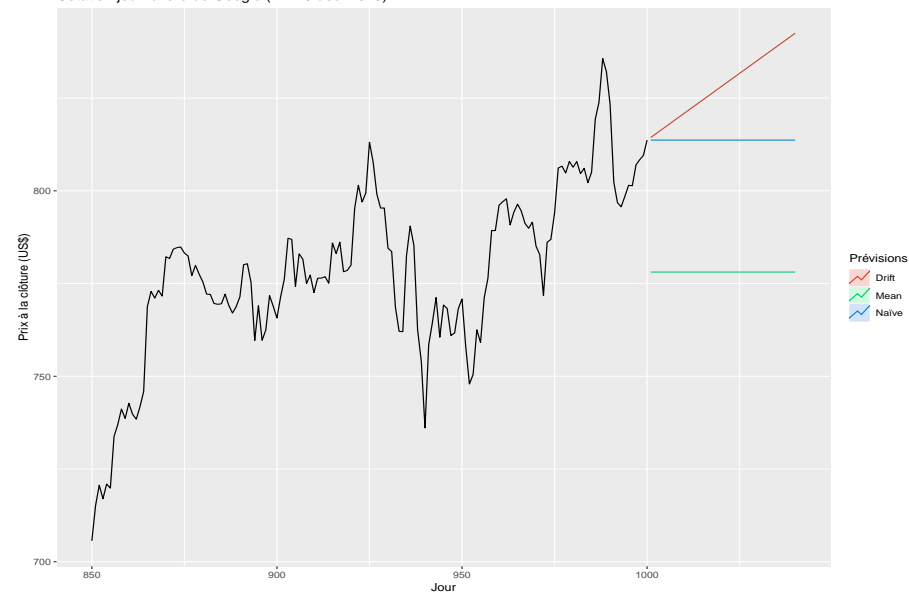
$$\hat{x}_{T+h|T} = x_T + \frac{h}{h-1}(x_T - x_1)$$

- Cela équivaut à extrapoler une ligne droite entre la première et la dernière observation.




## Quelques méthodes simples de prévision - suite

Cotation journalière de Google (fin : 6 déc. 2013)



## Quelques méthodes simples de prévision - suite

Prévisions pour la série trimestrielle de bière



## Quelques méthodes simples de prévision - Code "R"

- 1 Moyenne : `meanf(x,h=15)`
- 2 Naïve : `naive(x,h=15)`
- 3 Naïve saisonnière : `snaive(x,h=24)`
- 4 Dérive : `drift(x,drift=TRUE,h=20)`

## Stabilisation de la variance

Si la variabilité autour de la moyenne change au cours du temps, il peut alors être utile d'utiliser une transformation du type Box et Cox qui dépend d'un paramètre  $\lambda$  :


$$W_t = \begin{cases} \ln X_t & \text{si } \lambda = 0 \\ \frac{X_t^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0. \end{cases}$$

La valeur de  $\lambda$  peut être calculée via "R" sur l'exemple de la série "airline" :

```
(lambda <- BoxCox.lambda(airline))
[1] -0.2947156
```




## Série airline brute



## Série airline transformée

```
autoplot(BoxCox(airline,lambda))
```


Série transformée par Box et Cox : airline



## Série airline et prévisions

```
fit<-snaive(airline,lambda=-0.3)
autoplot(fit)
```

Prévisions de la série airline par la méthode saisonnière naïve



## Valeurs ajustées et résidus

- $\hat{x}_{t|t-1}$  est la prévision de  $x_t$  basée sur  $x_1, \dots, x_{t-1}$ . On les appelle valeurs ajustées.
- On notera :  $\hat{x}_t = \hat{x}_{t|t-1}$ .

## Exemple

- $\hat{x}_t = \bar{x}$  par la méthode de la moyenne.
- $\hat{x}_t = x_{t-1} + (x_T - x_1)/(T - 1)$  par la méthode de la dérive.



## Résidus

Un résidu à la date  $t$  est la différence entre la valeur observée et la valeur ajustée :

$$\varepsilon_t = x_t - \hat{x}_{t|t-1}.$$

## Hypothèses

- Les  $\varepsilon_t$  sont de moyenne nulle.
- Les  $\varepsilon_t$  sont deux à deux non corrélés.

## Propriétés utiles


- Les  $\varepsilon_t$  ont une variance constante.
- Les  $\varepsilon_t$  suivent une loi normale..



## Exemple : série google

```
autoplot(goog150) +
  xlab("Jour") + ylab("Prix de l'action à la clôture (dollars US)") +
  ggtitle("Action Google (fin le 6 déc. 2013)")
```

Action Google (fin le 6 déc. 2013)



## Exemple : série google - suite

La prévision naïve est :


$$x_t - \hat{x}_{t|t-1} = x_{t-1}.$$

Le résidu associé est donc :

$$\varepsilon_t = x_t - x_{t-1}.$$

## Exemple : série google - suite

```
fits <- fitted(naive(goog150))
autoplot(goog150, series="Données") +
  autolayer(fits, series="Ajustées") +
  xlab("Jour") + ylab("Prix de l'action à la clôture (en dollars US)")
+ ggtitle("Action Google (fin le 6 déc. 2013)")
```




Michel CARBON

R et la prévision des séries temporelles Chapitre 2 - Quelq

## Exemple : série google - résidus

```
res <- residuals(naive(goog150))
autoplot(res) + xlab("Jour") + ylab("") +
  ggtitle("Résidus obtenus par la méthode naïve")
```

Résidus obtenus par la méthode naïve




Michel CARBON

R et la prévision des séries temporelles Chapitre 2 - Quelq

## Exemple : série google - étude des résidus

```
checkresiduals(naive(goog150))
```



Michel CARBON

R et la prévision des séries temporelles Chapitre 2 - Quelq

## Exemple : série google - étude des résidus

Box-Ljung test

data : Residuals from Naive method,

 $Q^* = 15.623$ ,  $df = 10$ , **p-value = 0.111**

On ne rejette pas l'hypothèse que les résidus sont issus d'un bruit blanc.

Michel CARBON

R et la prévision des séries temporelles Chapitre 2 - Quelq

## Mesures de précision des prévisions

Soient  $x_t$  une observation et  $f_t$  sa prévision, pour tout  $t = 1, \dots, T$ .

$$MAE = \frac{1}{T} \sum_{t=1}^T |x_t - f_t|$$

$$MSE = \frac{1}{T} \sum_{t=1}^T (x_t - f_t)^2 \quad ; \quad RMSE = \sqrt{\frac{1}{T} \sum_{t=1}^T (x_t - f_t)^2}$$

$$MAPE = \frac{1}{100T} \sum_{t=1}^T (|x_t - f_t|)/|x_t|$$

Elles dépendent toutes de l'échelle des observations, sauf le **MAPE**.



## Mesures de précision des prévisions

Une autre mesure est le **MASE** (Mean Absolute Scale Error) :

$$MASE = \frac{1}{T} \sum_{t=1}^T |x_t - f_t|/q$$

où  $q$  est une mesure stable de l'échelle de la série  $(x_t)$ .

## Exemple

Pour une série non saisonnière :


$$q = \frac{1}{T-1} \sum_{t=2}^T |x_t - x_{t-1}|$$

fonctionne bien. Alors le **MASE** équivaut au **MAE** pour la méthode naïve.



## Mesures de précision des prévisions

Prévisions pour la production trimestrielle de bière



## Mesures de précision des prévisions

Le code "R" est le suivant :

```
biere2 <- window(biere,start=1992,end=c(2007,4))
bierefit1 <- meanf(biere2,h=10)
bierefit2 <- rwf(biere2,h=10)
bierefit3 <- snaive(biere2,h=10)
autoplot(window(biere, start=1992)) +
  autolayer(bierefit1, series="Moyenne", PI=FALSE) +
  autolayer(bierefit2, series="Naïve", PI=FALSE) +
  autolayer(bierefit3, series="Naïve saison.", PI=FALSE) +
  xlab("Années") + ylab("Mégalitres") +
  ggtitle("Prévisions pour la production trimestrielle de bière") +
  guides(colour=guide_legend(title="Prévisions"))
```



## Mesures de précision des prévisions

Le code "R" est :

```
biere3 <- window(biere, start=2008)
accuracy(bierefit1, biere3)
accuracy(bierefit2, biere3)
accuracy(bierefit3, biere3)
```

	MAE	MAPE	RMSE	MASE
Moyenne	34,83	8,28	38,45	2,44
Méth. naïve	57,40	14,18	62,69	4,01
Naïve saison.	13,40	3,17	14,31	0,94



## Intervalles de prévision

- Un intervalle de confiance est un intervalle dans lequel on espère que se situe  $x_{T+h}$  avec une certaine probabilité.
- Si on suppose les erreurs gaussiennes, alors l'intervalle de prévision à 95 % sera de la forme :

$$\hat{x}_{T+h} \pm 1,96 \times \hat{\sigma}_h$$

où  $\hat{\sigma}_h$  est l'écart-type associé à la loi pour  $h$  décalages.

- Quand  $h = 1$ ,  $\hat{\sigma}_1$  peut être estimé via les résidus.



## Intervalles de prévision

Prévisions naïves avec un intervalle de prévision :

```
res_sd <- sqrt(mean(res^2, na.rm=TRUE))
naive(goog150, level=95)
```

	Point Forecast	Lo 95	Hi 95
1001	813.67	799.0449	828.2951
1002	813.67	792.9869	834.3530
1003	813.67	788.3385	839.0015
1004	813.67	784.4197	842.9202
1005	813.67	780.9672	846.3728
1006	813.67	777.8459	849.4941
1007	813.67	774.9755	852.3644
1008	813.67	772.3039	855.0361
1009	813.67	769.7946	857.5454
1010	813.67	767.4213	859.9187



## Intervalles de prévision

## Remarque

- Il est très important d'avoir des intervalles de prévision, ce qui donne une information très pertinente sur l'efficacité des dites prévisions.
- Les intervalles de confiance requièrent que le modèle sous-jacent soit stochastique.
- Le calcul des prévisions à l'horizon  $h$  nécessitent une approche plus sophistiquée, avec des intervalles de confiance qui grossissent avec l'horizon  $h$  de prévision.



## Intervalles de prévision

Si les résidus sont gaussiens, non corrélés deux à deux, et d'écart-type  $\hat{\sigma}$ , on a :

① Méthode de la moyenne :  $\hat{\sigma}_h = \hat{\sigma} \sqrt{1 + 1/T}$

② Méthode naïve :  $\hat{\sigma}_h = \hat{\sigma} \sqrt{h}$

③ Méthode naïve saison. :  $\hat{\sigma}_h = \hat{\sigma} \sqrt{k + 1}$

④ Méthode de la dérive :  $\hat{\sigma}_h = \hat{\sigma} \sqrt{h(1 + h/T)}$


où  $k$  est la partie entière de  $(h - 1)/m$ .



## Intervalles de prévision

`autoplot(naive(goog150))`

Action Google avec prévisions et intervalles de prévision par la méthode naïve



## Exercice

À vous !

- ① Importez la série mensuelle "lait.dat" démarrant en janvier 2005. Tracez-là.
- ② Séparez les données en deux parties ( la première "lait.train" allant de janvier 2005 à décembre 2017, et l'autre "lait.test", démarrant en janvier 2018). Tracez-les.
- ③ Calculez les prévisions saisonnières naïves sur 12 mois à partir de la série "lait.train". Faites un graphique.
- ④ Comparez la pertinence de vos prévisions vis-à-vis du réalisé a posteriori.
- ⑤ Examinez les résidus. Commentez.

