

R et la prévision des séries temporelles

Chapitre 4 - Modèles ARIMA

Michel CARBON

Université Laval de Québec

13 mai 2019



Stationnarité

Une série stationnaire est une série dont les propriétés sont invariantes dans le temps.

Ainsi, les séries présentant une tendance ou une saisonnalité ne sont pas stationnaires.

Un bruit blanc est stationnaire.

En général, une série stationnaire est globalement de moyenne constante, également de variance constante (même si un comportement cyclique est possible), sans composantes prédictibles.




Le problème de la variance

Il faut, quand la variance n'est pas temporellement constante, effectuer une transformation de type Box et Cox.

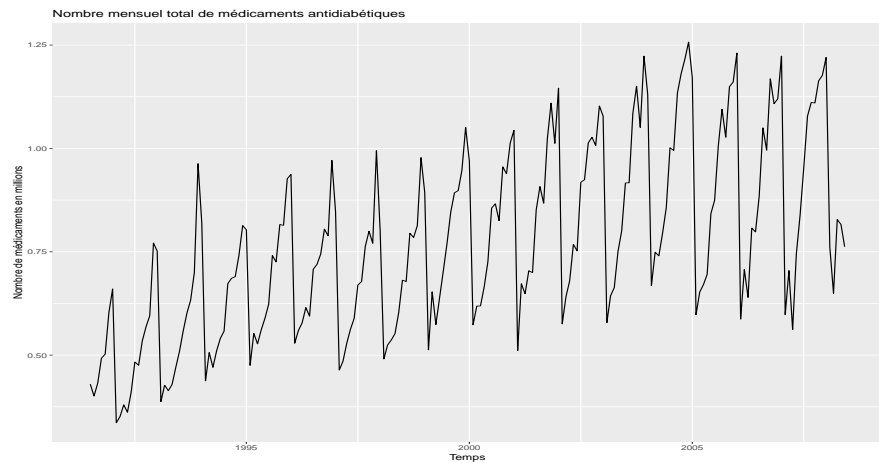
Cela a été vu au chapitre 2. J'insiste sur le fait que c'est la première chose à faire dans toute étude de série univariée.




Stationnarité - Exemple



Stationnarité - Exemple



Stationnarité - Exemple




Différenciation

La série "Google", notée (X_t) , vue ci-dessus, présente une tendance croissante (la série est donc non stationnaire).


Mais par différenciation, on obtient une série stationnaire (Y_t) :

$$Y_t = (I - B)X_t = X_t - X_{t-1}$$

Différenciation - Exemple




Différenciation - ACF de "Google" brute



Michel CARBON R et la prévision des séries temporelles Chapitre 4 - Modél

Différenciation - ACF de "Google" différenciée



Michel CARBON R et la prévision des séries temporelles Chapitre 4 - Modél


Différenciation saisonnière

On peut être amené à différencier saisonnièrement. Par exemple, sur la série (X_t) des "médicaments antidiabétiques", on est amené à différencier la saison ($s = 12$), donnant la série :

$$Y_t = (I - B^{12})X_t = X_t - X_{t-12}$$

Michel CARBON R et la prévision des séries temporelles Chapitre 4 - Modél

Différenciation saisonnière - Exemple



Michel CARBON R et la prévision des séries temporelles Chapitre 4 - Modél

Différenciation multiple

Il existe des tests statistiques pour savoir quel degré de différenciation appliquer :

- ❶ Le test de Dickey-Fuller augmenté : l'hypothèse nulle est que la série est non stationnaire et non saisonnière.
- ❷ Le test de Kwiatkowski-Phillips-Schmidt-Shin (KPSS) : l'hypothèse nulle est que la série est stationnaire et non saisonnière.
- ❸ D'autres tests sont applicables pour les séries saisonnières.



Différenciation multiple - Exemple

```
> adf.test(goog150)
```

Augmented Dickey-Fuller Test

data: goog150

Dickey-Fuller = -3.1913, Lag order = 5, p-value = 0.09201

alternative hypothesis: stationary



Différenciation multiple - Exemple

```
> summary(ur.kpss(goog150))
```

```
#####
# KPSS Unit Root Test #
#####
```

Test is of type: mu with 4 lags.

Value of test-statistic is: 1.5337

Critical value for a significance level of:

	10pct	5pct	2.5pct	1pct
critical values	0.347	0.463	0.574	0.739



Le modèle ARIMA - SARIMA

Le modèle complet est :

$$\Phi_p(B) \Phi_P(B^S) \nabla^d \nabla_S^D X_t = \Theta_q(B) \Theta_Q(B^S) \varepsilon_t \quad (1)$$



Notations

Notations :

S est la période de la saisonnalité ($S = 12$ dans l'exemple précédent, $S = 4$ pour des séries trimestrielles,...).

$\nabla = 1 - B$; $\nabla_S = 1 - B^S$; $\Phi_p, \Phi_P, \Theta_q, \Theta_Q$ sont des polynômes de degrés respectifs p, P, q, Q dont les racines sont de modules strictement supérieurs à 1, et $(\varepsilon_t)_{t \in \mathbb{Z}}$ est un bruit blanc.

Un processus X_t satisfaisant (1) est appelé processus

$$SARIMA_S [(p, d, q), (P, D, Q)]$$




La commande "auto.arima"


- ❶ Recherche éventuelle de points aberrants ou manquants.
- ❷ Le cas échéant, stabilisez la variance via une transformation de Box et Cox.
- ❸ Utilisez la commande "auto.arima" pour sélectionner un modèle.
- ❹ Faire une analyse des résidus qui devraient être la réalisation d'un bruit blanc gaussien. Si cela n'a pas lieu, il faudra modifier le modèle.
- ❺ Une fois cela réalisé, on peut utiliser le modèle pour faire des prévisions.



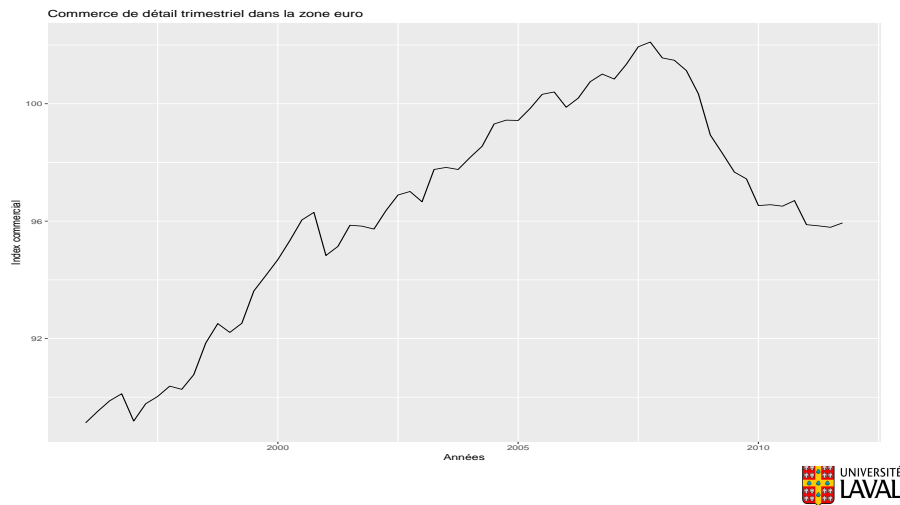
Valeurs manquantes



Valeurs manquantes et aberrantes - Commande "tsclean"



Commande "auto.arima" - Exemple



Michel CARBON

R et la prévision des séries temporelles Chapitre 4 - Modél

Commande "auto.arima" - Exemple

```
euretail %>% auto.arima() %>% forecast(h=12) %>% autoplot() +
  ylab("Index commercial") + xlab("Années")+
  ggtitle("Commerce de détail trimestriel dans la zone euro et
```

Series: .
ARIMA(0,1,3)(0,1,1)[4]

Coefficients:

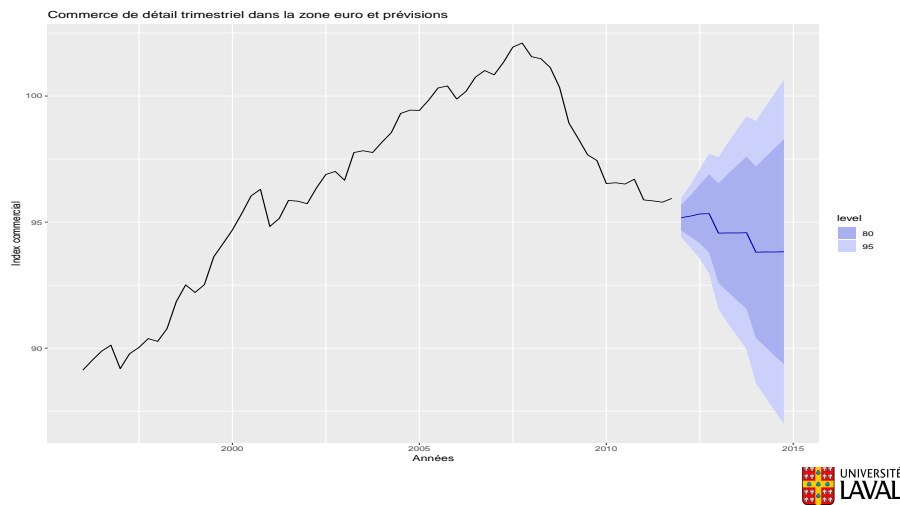
	ma1	ma2	ma3	sma1
	0.2630	0.3694	0.4200	-0.6636
s.e.	0.1237	0.1255	0.1294	0.1545

sigma^2 estimated as 0.156: log likelihood=-28.63
AIC=67.26 AICc=68.39 BIC=77.65

Michel CARBON

R et la prévision des séries temporelles Chapitre 4 - Modél


Commande "auto.arima" - Exemple



Michel CARBON

R et la prévision des séries temporelles Chapitre 4 - Modél

Commande "auto.arima" - Exemple



Michel CARBON

R et la prévision des séries temporelles Chapitre 4 - Modél

Commande "auto.arima" - Exemple

```
h02 %>% auto.arima()%>% forecast(h=24) %>% autoplot()+
  ggtitle("Nombre mensuel total de médicaments antidiabétiques et prévisions")
  xlab("Temps")+
  ylab("Nombre de médicaments en millions")
```

Series: .
ARIMA(4,1,1)(0,1,2)[12]


Coefficients:

	ar1	ar2	ar3	ar4	ma1	sma1	sma2
	0.0888	0.3386	0.2302	-0.2233	-0.9068	-0.4798	-0.1624
s.e.	0.1063	0.0976	0.0894	0.0850	0.0853	0.0913	0.0930

sigma^2 estimated as 0.00276: log likelihood=291.7
AIC=-567.4 AICc=-566.6 BIC=-541.38



Commande "auto.arima" - Exemple



Commande "auto.arima" - Exemple

On doit analyser les résidus :

```
fit.arima<-auto.arima(h02)
checkresiduals(fit.arima)
```


Ljung-Box test

data: Residuals from ARIMA(4,1,1)(0,1,2)[12]
Q* = 26.081, df = 17, p-value = 0.07299

Model df: 7. Total lags used: 24



Commande "auto.arima" - Exemple



Commande "auto.arima" - Exemple

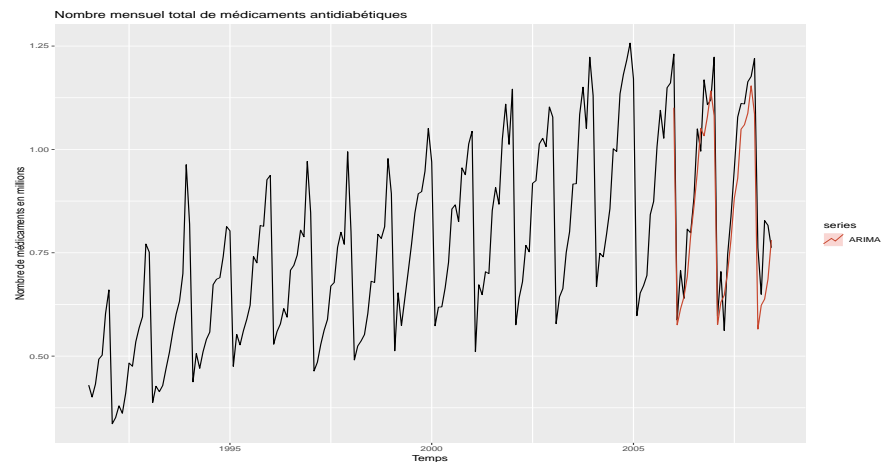
On peut faire un test d'évaluation de la pertinence des prévisions.
Ici, on va retrancher 2 ans.

```
train <- window(h02,end=c(2005,12))
(fit.arima<-auto.arima(train))
diab1<-fit.arima %>% forecast(h=24)%>%
  accuracy(h02)
diab1[,c("RMSE","MAPE","MASE")]
```


	RMSE	MAPE	MASE
Training set	0.04588769	4.568735	0.5600418
Test set	0.07927912	7.013943	1.0942005



Commande "auto.arima" - Exemple



Commande "auto.arima" - Exemple



Commande "auto.arima" - Exemple

```
airline %>% auto.arima(lambda="auto") %>% forecast(h=24)%>%
  autoplot()+
  ggtitle("Nombre mensuel de passagers sur les vols aériens interna
  xlab("Temps")+ ylab("Nombre de passagers (en milliers)")
```

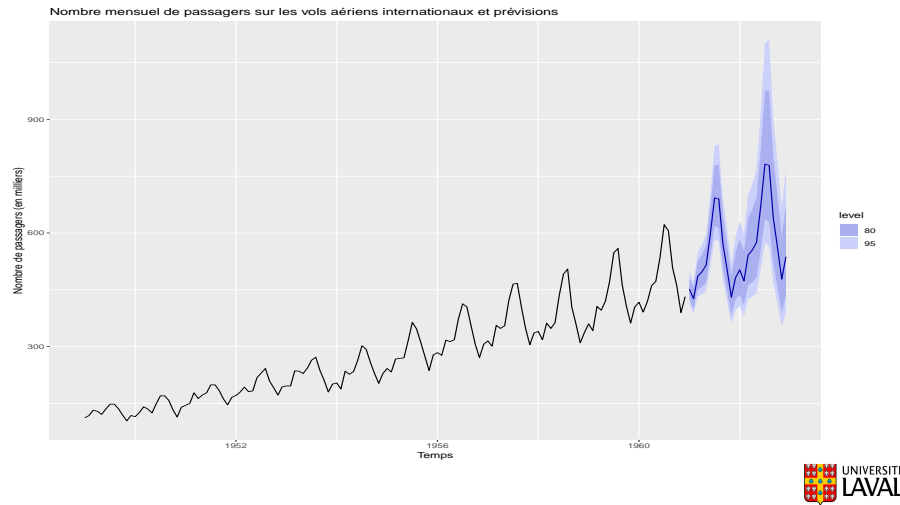
```
Series: .
ARIMA(0,1,1)(0,1,1)[12]
Box Cox transformation: lambda= -0.2947156
```

```
Coefficients:
      ma1      sma1
-0.4355 -0.5847
s.e.    0.0908  0.0725
```

```
sigma^2 estimated as 5.855e-05: log likelihood=451.6
AIC=-897.19 AICc=-897.01 BIC=-888.57
```



Commande "auto.arima" - Exemple



Michel CARBON

R et la prévision des séries temporelles Chapitre 4 - Modél

Commande "auto.arima" - Exemple

On doit analyser les résidus :

```
fit1.arima<-auto.arima(airline,lambda="auto")
checkresiduals(fit1.arima)
```

Ljung-Box test


```
data: Residuals from ARIMA(0,1,1)(0,1,1)[12]
Q* = 28.635, df = 22, p-value = 0.1556
```

Model df: 2. Total lags used: 24

Michel CARBON

R et la prévision des séries temporelles Chapitre 4 - Modél

Commande "auto.arima" - Exemple



Michel CARBON

R et la prévision des séries temporelles Chapitre 4 - Modél

Exercice

À vous !

- ① Importez la série "electricity.dat", série mensuelle débutant en janvier 1986. Faites-en un graphique.
- ② En utilisant un modèle SARIMA, faites des prévisions sur 2 ans.
- ③ Tronquez fictivement les 60 dernières observations et faites des prévisions via un modèle SARIMA et une approche "ets".
- ④ Comparez l'efficacité prévisionnelle des deux approches.

Michel CARBON

R et la prévision des séries temporelles Chapitre 4 - Modél